

Compresión de imágenes y vídeos usando wavelets

Análisis de Señales. Máster en Ciencia de Datos - UV

Juan Alcaraz, Adrián Carrasco, Fabián Calvo, Javier Herrero y Clara Montalvá

Curso 2025-2026

Contents

1	Introducción	2
2	Revisión bibliográfica	2
3	Objetivos	3
4	Descripción de los datos	3
5	Metodología	4
5.1	Bases para comprender la compresión de imágenes	5
5.1.1	Contexto inicial: codificador y decodificador	5
5.2	Compresión DWT	5
5.3	Compresión DCT	5
5.4	Compresión EZW y SPIHT	6
5.4.1	Funcionamiento básico de los algoritmos	6
5.5	Compresión de vídeo	7
5.5.1	Compresión de imagen	7
5.5.2	Compresión de audio	7
5.6	Métricas de error	8
6	Resultados	9
6.1	Compresión de imágenes	9
6.1.1	Compresiones DWT y DCT	9
6.1.2	Compresión SPIHT y posibles mejoras	13
6.2	Compresión de vídeo	14
6.2.1	Compresión de imágenes del vídeo	14
6.2.2	Compresión del audio del vídeo	14

7 Conclusiones	16
8 Link del repositorio	17
Referencias	17

1 Introducción

En la era de la información en la que vivimos, la capacidad de almacenar y compartir archivos multimedia de forma eficiente es una necesidad fundamental. Debido al gran tamaño de las imágenes y vídeos actuales, es imprescindible utilizar técnicas de compresión que reduzcan el peso de los archivos sin que la pérdida de calidad sea demasiado evidente para el usuario.

Históricamente, el método de compresión más utilizado ha sido el de la Transformada de Coseno Discreta (DCT), que es la base del formato JPEG. Aunque este método es eficaz, suele generar distorsiones visuales cuando se busca una compresión muy alta. Como alternativa, surgió la Transformada de Wavelet Discreta (DWT), que analiza la información en diferentes niveles de detalle y permite una reconstrucción más limpia.

2 Revisión bibliográfica

La base teórica sobre la que se sustenta todo el trabajo realizado es el análisis de Fourier. Históricamente, este ha sido de una incommensurable utilidad en lo que se refiere a la ciencia en general y al análisis de señales en particular, siendo las wavelets la evolución natural de la transformada de Fourier.

Desde una perspectiva matemática, esta transformada puede interpretarse como un de producto escalar. Más concretamente, la transformada de Fourier de una función f , puede verse como $\mathcal{F}\{f\}(s) = \langle f, e^{isx} \rangle$, donde $\langle, \rangle$ denota un cierto producto escalar entre funciones.

Las wavelet surgieron al considerar el producto escalar con otras funciones distintas, las denominadas wavelets madre. Así, dada una wavelet madre ψ , la transformada wavelet de una cierta señal f será $\langle f, \psi(\frac{t-a}{b}) \rangle$.

Las wavelets permiten hacer un análisis en el dominio de frecuencias de las señales y tiene aplicaciones muy diversas. En este trabajo, como se ha mencionado anteriormente, las aplicaremos para la compresión de imágenes y vídeos.

La compresión de imágenes se fundamenta en la premisa de que los archivos digitales de las imágenes contienen una cantidad importante de datos que no necesariamente aportan información relevante. Como se establece en el libro “Digital Image Processing” de González y Woods (2018) [1], los datos son el medio a través del cual se transporta la información y la cantidad de datos utilizados usualmente excede la cantidad de información real contenida, siendo este exceso comúnmente conocido como redundancia.

El objetivo central de los algoritmos de compresión utilizados en este proyecto es la reducción de dicha redundancia. Según la literatura de González y Woods [1], existen dos tipos distintos de redundancia, ambos muy importantes para el funcionamiento de las transformadas DCT y Wavelets.

- Redundancia Interpixel: Es una redundancia estadística, y surge debido a las correlaciones existentes entre píxeles vecinos. Implica que el valor de un píxel puede predecirse bien a partir de píxeles vecinos.
- Redundancia Psicovisual: Es una redundancia asociada a la percepción que tiene el humano de las imágenes. No toda la información visual que contiene una imagen es percibida con la misma importancia. Es por ello que en la compresión con pérdida se puede eliminar redundancia en una imagen y que para el ojo humano el cambio en la imagen sea imperceptible.

Históricamente, la compresión de imágenes ha dependido de transformadas ortogonales para concentrar la energía de la señal en pocos coeficientes. El estándar se ha basado en la Transformada de Coseno Discreta (DCT), por su capacidad de compactación y debido a que su coste computacional no es muy alto. Este método divide la imagen en bloques de 8x8 píxeles y procesa cada uno de estos bloques.

La investigación ha llevado a distintas alternativas a la DCT, una de ellas la Transformada Discreta de Wavelet (DWT), que utiliza wavelets localizadas tanto en tiempo como en frecuencia. Esto permite la descomposición de la imagen en bandas de aproximación y detalle a diferentes escalas.

Otra alternativa, son los algoritmos “Embedded Zerotree Wavelet” (EZW) y “Set Partitioning in Hierarchical Trees” (SPIHT) que, a diferencia de los métodos tradicionales que tratan los coeficientes de manera aislada, organizan los coeficientes en árboles de orientación espacial y clasifican los coeficientes por magnitud, transmitiendo primero los bits más significativos de los coeficientes más grandes.

Estos métodos utilizados para la compresión de imágenes se pueden utilizar también para la compresión de vídeo, entendiendo que un vídeo es una secuencia de frames que se pueden comprimir individualmente, con el añadido de que, además de la redundancia espacial y psicovisual presente en cada frame, el vídeo introduce también la redundancia temporal. Como explican Sullivan y Wiegand (2005) [2] en su revisión sobre los estándares de vídeo, los cuadros adyacentes en una secuencia de vídeo suelen exhibir una alta correlación, ya que el movimiento entre un instante y el siguiente suele ser suave.

3 Objetivos

Evaluaremos y compararemos la eficacia de los algoritmos de compresión DWT (Discrete Wavelet Transform), DCT (Discrete Cosine Transform) y SPIHT (Set Partitioning in Hierarchical Trees) aplicados a imágenes y a vídeos.

Para las imágenes, seleccionaremos cinco imágenes con características diversas. Esta selección nos permitirá observar cómo cada algoritmo gestiona conceptos como la entropía, la retención de nitidez y el ruido.

Para la aplicación a la compresión de vídeos, necesitaremos comprimir también el audio. Para ello, exploraremos el dominio wavelet mediante el mejor valor umbral de energía, analizando la redundancia de la señal a través de la entropía de Shannon. Esto nos permitirá comprender la relación entre la concentración de energía de una señal y su capacidad para ser comprimida.

Para la evaluación de los diferentes algoritmos haremos un análisis de métricas de error como el MSE y el PSNR, el SSIM, la entropía o el CR. Trataremos de determinar qué método ofrece el mayor equilibrio entre la reducción del peso de la imagen y la mejor reconstrucción visual posible de la misma.

4 Descripción de los datos

Para evaluar la eficacia de los algoritmos de compresión, hemos seleccionado un conjunto de cuatro imágenes propias y una imagen de la librería `imager` de R con características visuales y tamaños distintos, lo que nos permitirá observar cómo responden los diferentes métodos de compresión y sus parámetros ante diferentes niveles de entropía, detalle y dimensiones de los datos.

La primera fotografía escogida es de un acantilado, que al ser dominada por el azul del mar y el cielo, cuenta con grandes zonas de color uniforme. Esto nos permite evaluar la eficiencia de la compresión en imágenes con “poca información” aparente o redundancia, donde los algoritmos deberían optimizar mejor el peso del archivo.

La segunda imagen contiene una gran variedad de colores y tonos a lo largo de toda la imagen, ya que se trata de una fotografía de distintas flores. Al contrario que la anterior, esta imagen sirve para probar cómo los algoritmos gestionan la retención del color y la nitidez en zonas con mucha información visual y cambios de color constantes.

La tercera fotografía se trata de una imagen nocturna de una avenida, utilizada para analizar qué ocurre en condiciones de poca luz. En estas imágenes suele aparecer ruido digital y sombras, lo que supone un reto donde la pérdida de información suele ser más evidente tras aplicar los procesos de compresión.

La cuarta imagen, se escogió una imagen generada mediante Inteligencia Artificial recreando a los cinco miembros del grupo al estilo del Estudio Ghibli. Al no estar capturada por una cámara real, sino generada digitalmente, posee bordes definidos y colores planos que nos sirven para comparar cómo se comporta la compresión en creación digital.

Por último, utilizaremos la imagen **boats** de la librería **imager**, cuyas dimensiones son bastante más pequeñas que las de las otras cuatro. Esto nos permitirá aplicarle el algoritmo SPIHT, ya que para las otras imágenes el tiempo de computación y el espacio en memoria necesario para almacenar las variables internas que se crean es demasiado elevado.

Acantilado



Flores



Noche



Dibujo



Barcos



Para el estudio de la compresión de vídeo se ha utilizado un único vídeo elaborado por nosotros. Al vídeo se le ha añadido música de fondo con el objetivo de enriquecer el contenido de audio. Tiene una duración total de 7 segundos y fue grabado a una tasa de 30 fotogramas por segundo.

El archivo de vídeo puede consultarse en el siguiente enlace: https://github.com/JuanAlcarazAED/Trabajo_AS/blob/main/data/video.mp4.

5 Metodología

Recordemos, en primer lugar, que las wavelets son funciones matemáticas que permiten descomponer una señal en sus componentes de frecuencia a diferentes escalas, proporcionando una representación conjunta en el dominio del tiempo y la frecuencia.

Debido a que una señal (o función) se puede representar en términos de los coeficientes de una expansión en wavelets, las operaciones de datos se pueden realizar usando solo los coeficientes wavelet correspondientes. Esto permite que, eligiendo las wavelets mejor adaptadas a los datos o truncando los coeficientes debajo de un cierto umbral, los datos se puedan representar con un número reducido de estos coeficientes.

Las wavelets son, por tanto, muy útiles en el campo de la compresión de datos y de la reducción de ruido.

5.1 Bases para comprender la compresión de imágenes

5.1.1 Contexto inicial: codificador y decodificador

La idea sobre la que se sustentan todos los métodos de compresión consiste en tomar la transformada wavelet de una imagen y almacenar la información de la matriz de coeficientes wavelet (o una parte de ella) en una cadena de *bits*, llamada *bitstream*. Esta tarea la hace un codificador.

Será el *bitstream* lo que se enviará y/o se almacenará, según el uso que le queramos dar. Esta transformación sirve, primero para poder transmitir la información por un canal binario y además porque esta cadena ocupa, en general, menos espacio en memoria.

Sin embargo, cuando el usuario final quiere recuperar la imagen, se necesita realizar el proceso inverso al que hizo el codificador. Este proceso lo realiza el llamado decodificador, que recupera la información a partir del *bitstream*.

Cada uno de los siguientes algoritmos tiene una forma distinta de codificar la información de los coeficientes wavelet.

5.2 Compresión DWT

La DWT (Discrete Wavelet Transform) es el proceso matemático y algorítmico utilizado para descomponer la señal original $x[n]$ en una serie de coeficientes wavelet (coeficientes de aproximación y detalle), que representan la señal en distintos dominios de frecuencia y tiempo. Mientras que la IDWT (Inverse Discrete Wavelet Transform) busca reconstruir la señal, la DWT realiza el camino de análisis, separando la información en distintos niveles de resolución para aislar características específicas.

El proceso de descomposición se basa en el esquema del Algoritmo de Mallat:

1. Proceso Iterativo: La descomposición comienza desde la señal original (alta resolución) y avanza iterativamente hacia abajo, generando niveles de resolución cada vez más bajos (frecuencias más bajas).
2. Separación de Coeficientes: En cada nivel, la señal se divide en dos conjuntos: los coeficientes de aproximación (que capturan bajas frecuencias) y los coeficientes de detalle (que capturan altas frecuencias).
3. Filtrado: Matemáticamente, esto implica pasar la señal por filtros (paso bajo y paso alto) seguido de una operación de submuestreo (eliminar muestras alternas).

En imágenes, la DWT separa la información visual original, en bandas: una versión reducida de la imagen (aproximación) y conjuntos de detalles (verticales, horizontales y diagonales). Esta separación es lo que permite, posteriormente, descartar información menos visible (compresión) antes de reconstruir.

5.3 Compresión DCT

La DCT es una operación matemática relacionada con la Transformada de Fourier, pero trabaja solo con números reales (cosenos). Su función principal no es comprimir por sí misma, sino traducir la información de la imagen. Pasa de píxeles de colores (dominio espacial) a frecuencias (dominio de la frecuencia) [3].

Esto se realiza porque el ojo humano es muy sensible a las frecuencias bajas (cambios suaves de color) pero muy poco sensible a las frecuencias altas (detalles finos o ruido). Al separar estas frecuencias, podemos eliminar las que el ojo no ve bien sin que se note demasiado.

Con este método la imagen se divide en bloques de 8x8 píxeles. Al aplicar la fórmula matemática a cada bloque, se obtiene una matriz de frecuencias donde:

- Esquina superior izquierda (Componente DC): Contiene la información más importante (el color promedio del bloque).
- Esquina inferior derecha (Componentes AC): Contienen las frecuencias altas (detalles finos). Aquí es donde se acumulan valores pequeños o prescindibles.

Dicha matriz de frecuencias se divide por una “Matriz de Cuantización” predefinida (Q).

- El objetivo es que los valores de las frecuencias altas (los detalles que el ojo casi no ve) se conviertan en ceros o números muy bajos al dividirse por números grandes.
- Es el único paso donde realmente se pierde información irrecuperable.
- La “Calidad” del JPG (ej. 50% vs 80%) depende de qué tan agresiva sea esta matriz.

Finalmente, se aplica el algoritmo de Huffman. Se asignan códigos binarios muy cortos a los valores que se repiten mucho y códigos más largos a los poco frecuentes. Esto comprime aún más el archivo final sin perder datos adicionales.

5.4 Compresión EZW y SPIHT

A parte de los algoritmos ya mencionados, los cuales son los más conocidos, para dar una visión más amplia del campo de la compresión de imágenes decidimos incluir dos algoritmos más también basados en la transformada wavelet.

Estos dos algoritmos llamados EZW (*Embedded Zerotree Wavelet*) y SPIHT (*Set Partitioning in Hierarchical Trees*) tienen la misma idea base, tomar la transformada wavelet de una imagen, hacer una selección de los coeficientes más importantes y aproximar su valor.

Dado que el funcionamiento detallado de los dos algoritmos es muy extenso, haremos aquí un pequeño resumen del mismo y de sus ideas principales.

5.4.1 Funcionamiento básico de los algoritmos

Los dos algoritmos tienen el mismo fundamento base, se recorren las posiciones de la matriz de coeficientes wavelet en busca de los más importantes.

Se hace un bucle y cada iteración tiene dos fases, la primera de las cuales es el llamado paso dominante, que trata de encontrar los coeficientes wavelet significativos. Si un coeficiente es significativo o no se decide en función de una cierta cota T . Luego está el paso subordinado, que trata de aproximar el valor de los coeficientes encontrados en el paso anterior.

Después de cada iteración se reduce a la mitad la cota usada para medir la significancia y se repite el proceso. El algoritmo finaliza cuando la cota toma un valor menor o igual a 1.

Sin dar muchos detalles, la forma en la que se organizan los algoritmos se basa en darle una estructura de árbol a la matriz de coeficientes, se establece que el coeficiente en la posición (i, j) tiene hijos, que son $(2i, 2j)$, $(2i + 1, 2j)$, $(2i, 2j + 1)$ y $(2i + 1, 2j + 1)$. Con este convenio se forma una estructura que permite analizar los coeficientes de forma eficaz.

La diferencia principal entre ambos algoritmos es la forma de recorrer la matriz de coeficientes. En ambos casos se aprovecha la estructura de árbol explicada, pero en EZW se recorre la matriz siguiendo un orden de barrido específico, para no analizar nunca un coeficiente hijo antes que su padre, mientras que en SPIHT, que es una versión más refinada de EZW, se tienen tres listas LIS, LIP y LSP, las cuales contienen índices de los coeficientes, y siguiendo ciertas directrices se recorren las listas y se traspasan elementos de unas a otras o se añaden nuevos elementos en función de si los coeficientes son significativos o no.

Una explicación más detallada de ambos algoritmos se puede encontrar en el repositorio del proyecto, en el archivo `Explicacion_Algoritmos_EZW_SPIHT.rmd` dentro de la carpeta `explicaciones_y_pruebas/`. Para entender el funcionamiento de los algoritmos, se ha consultado el libro [4].

También se ha implementado una versión rudimentaria del algoritmo SPIHT, no se ha implementado EZW por falta de tiempo y porque SPIHT es claramente mejor. Hemos elegido implementarlo nosotros mismos porque no hemos encontrado ninguna librería de R que ya lo implemente. Si bien es cierto que encontramos una librería de Python que podríamos haber llamado desde R, esta era muy compleja de usar y además era necesario tener nociones del lenguaje de programación Rust, lenguaje que el autor de la librería mencionada emplea para la implementación del método.

Enlace al repositorio donde se encuentra la librería mencionada: [aquí](#)

5.5 Compresión de vídeo

Para abordar la compresión del vídeo, separaremos sus imágenes o fotogramas (frames) del audio y realizaremos las compresiones de ambas partes por separado.

5.5.1 Compresión de imagen

Para la compresión de los fotogramas, le aplicaremos el algoritmo DCT a cada uno de ellos.

5.5.2 Compresión de audio


La compresión del audio se va a realizar en el dominio wavelet mediante el umbralado selectivo de la energía de los coeficientes, aplicándose exclusivamente sobre las componentes de detalle. Esta elección se debe a que los coeficientes de detalle presentan una mayor dispersión energética. El planteamiento se centra en estudiar la redundancia de la señal, utilizando la entropía de Shannon calculada a partir de la distribución de energías de la señal umbralizada [5]. Se busca un equilibrio entre maximizar la redundancia y la compresión del archivo sin perder información relevante.

La compresión se realiza mediante un umbralado global basado en la energía acumulada de los coeficientes wavelet. Sea c_i con $i = 1, \dots, N$ el conjunto de coeficientes de la señal. La energía asociada a cada coeficiente es $E_i = |c_i|^2$. En primer lugar, los coeficientes se ordenan de mayor a menor energía $|c_1|^2 \geq |c_2|^2 \geq \dots \geq |c_N|^2$ con el objetivo de indentificar la contribución relativa a la señal. La energía total se define como $E_{total} = \sum_{i=1}^N |c_i|^2$ y la energía acumulada $E_{cap}(k) = \sum_{i=1}^k E_{(i)}$ donde $E_{(i)}$ es la energía del i -ésimo coeficiente en el orden descendente.

Dado un parámetro $\lambda \in [0, 1]$, que representa la fracción de energía total que se desea eliminar, se anulan todos aquellos coeficientes cuya energía acumulada verifique $E_{cap}(k) \leq \lambda E_{total}$.

La frecuencia de muestreo del audio es de 44100 Hz, dado que cada nivel de descomposición divide el espectro a la mitad, elegir 6 niveles es razonable ya que se llega a cubrir las frecuencias medias y bajas donde se concentra energías.

El audio a estudiar está en estéreo, la amplitud del audio para ambos canales se puede observar en la siguiente figura.



La compresión de una señal mediante umbralizado de energía en el dominio wavelet busca concentrar la energía de la señal en un número reducido de coeficientes, eliminando aquellos que aportan poca contribución energética. Este proceso modifica la distribución estadística de la energía, haciendo que esta se concentre en menos estados. Como consecuencia la señal resultante presenta una distribución menos uniforme, lo que conlleva a una reducción de la entropía.

Para analizar de forma cuantitativa este efecto, se estudia la entropía de Shannon asociada a la distribución de energía de los coeficientes wavelet tras haber umbralizado. La entropía se calcula a partir del histograma de energías, en el que cada bin representa un símbolo discreto. De esta forma se puede medir de manera robusta el grado de concentración energética dado por el parámetro umbral λ . Con el fin de normalizar la magnitud se introduce el concepto de redundancia definida como $R(\lambda) = 1 - \frac{H(\lambda)}{H_{max}}$. Donde $H(\lambda)$ es la entropía de la distribución de energía de los coeficientes wavelet tras umbralizar y $H_{max} = \log_2(N_{bins})$ con N_{bins} el número de bins que se mantiene constante para todos los valores de λ . Una redundancia elevada indica que la entropía de la señal está concentrada en un número reducido de estados, lo que indica que la señal presenta una alta compresibilidad.

Se ha seleccionado el formato `.rds` para el análisis del almacenamiento debido a su capacidad para preservar la estructura de los coeficientes wavelet, incluyendo los valores nulos generados por el umbralado. A diferencia del formato `.wav`, que almacena la señal reconstruida en el dominio temporal sin tener en cuenta la presencia de ceros. El porcentaje de archivo comprimido se calcula como el tamaño relativo del archivo `.rds` normalizado respecto al tamaño máximo obtenido para $\lambda = 0$, correspondiente al caso sin compresión. De esta manera, esta magnitud refleja la reducción de información estructural debida al umbralado.

5.6 Métricas de error

Para la evaluación de los resultados obtenidos tras la compresión de las diferentes imágenes utilizaremos, además de la evaluación visual subjetiva, una serie de métricas de error que nos permitirán valorar tanto la fidelidad en la reconstrucción de la imagen como la eficiencia computacional del proceso.

Las dos métricas más utilizadas en el contexto de compresión de imágenes y más simples son el Error Cuadrático Medio (MSE) y la Proporción Máxima de Señal a Ruido (PSNR), esta última expresada en decibelios. Ambas son métricas basadas en el error de píxeles. Un mayor PSNR indicará una mayor calidad de la imagen y un menor MSE significará, evidentemente, que hay una menor diferencia entre la imagen comprimida y la original.

Ahora bien, estas dos métricas no reflejan bien la calidad de imagen percibida por el ojo humano. Buscando encontrar una medida cuantitativa que representase esta “calidad percibida” subjetiva, Zhou Wang, Alan Bovik, Hamid Sheikh y Eero Simoncelli desarrollaron en [6] el llamado Índice de Similitud Estructural (SSIM), el cual considera la degradación de una imagen como cambios en la información estructural, no solo como errores de píxeles absolutos. Compara cambios en la luminancia, el contraste y la estructura de las imágenes.

Por otra parte, al tratarse de algoritmos de compresión, también estaremos interesados en analizar la Tasa o Ratio de Compresión (CR) y la entropía de las imágenes. La primera de estas métrica medirá la relación entre el tamaño del archivo original y el comprimido, indicando cuánto espacio en memoria hemos ganado, y la segunda mide la cantidad de información contenida en la imagen (la compararemos con la de la imagen original). Se mide en bits/píxel.

Un detalle a tener en cuenta a la hora de comparar el tamaño de las imágenes originales y las comprimidas es que los formatos en los que se guardan las imágenes en un ordenador ya realizan compresiones implícitas. Por tanto, podemos obtener resultados aparentemente contradictorios como que los archivos comprimidos ocupen más espacio que los originales (los cuales ya estaban comprimidos). Además, el simple hecho de cargar una imagen externa en R y volverla a guardar sin modificarla ya hace que cambie su espacio en memoria.

Con todo esto, para que la métrica CR sea lo más útil y representativa posible, cargaremos inicialmente todas las imágenes en R y las volveremos a guardar directamente (modificando su tamaño).

Por último, para determinar el coste computacional de cada uno de los algoritmos calcularemos el tiempo de ejecución de cada uno de ellos en segundos.

6 Resultados

6.1 Compresión de imágenes

6.1.1 Compresiones DWT y DCT

En esta sección simplemente mostraremos la comparativa entre las imágenes originales y las comprimidas y tablas con las diferentes métricas de error descritas en el apartado de Metodología.



A simple vista se observa como la compresión DWT hace que la imagen sea más borrosa y la de DCT que aparezca ruido. Si calculamos las métricas de error para ambas compresiones, obtenemos la siguiente tabla.

Table 1: Compresión acantilado

	MSE	PSNR (dB)	SSIM	CR	Entropía (bits/píxel)	Tiempo (s)
DWT	0.0027	25.68	0.9723	1.657	7.22	3.81
DCT	0.0010	30.07	0.9901	0.808	7.29	4.89

Nota: La entropía de la imagen original es de 7.31 bits/píxel.

Notamos que la tasa de compresión (CR) para la compresión DCT es menor que 1. Es decir, que el espacio en memoria que ocupa la imagen comprimida es mayor al de la imagen original. Esto es debido a que no realizamos una codificación adecuada tras la aplicación de la DCT y el umbral, o al menos no tan eficiente como la del estándar **jpg** y **jpeg**. No obstante, si comprobamos la cantidad de ceros en las matrices correspondientes a cada una de las imágenes



Table 2: Compresión flores

	MSE	PSNR (dB)	SSIM	CR	Entropía (bits/píxel)	Tiempo (s)
DWT	0.0056	22.52	0.9602	1.425	7.81	13.97
DCT	0.0010	30.07	0.9932	0.838	7.84	17.72

Nota: La entropía de la imagen original es de 7.83 bits/píxel.



De nuevo observamos el mismo efecto que para la imagen del acantilado.

Table 3: Compresión noche

	MSE	PSNR (dB)	SSIM	CR	Entropía (bits/píxel)	Tiempo (s)
DWT	0.0021	26.79	0.9834	1.642	7.08	13.00
DCT	0.0005	32.95	0.9960	0.899	7.13	13.28

Nota: La entropía de la imagen original es de 7.14 bits/píxel.

Imagen dibujo



Compresión DWT



Compresión DCT



Table 4: Compresión dibujo

	MSE	PSNR (dB)	SSIM	CR	Entropía (bits/píxel)	Tiempo (s)
DWT	0.0026	25.84	0.9779	1.773	7.55	3.50
DCT	0.0007	31.25	0.9937	1.165	7.57	3.25

Nota: La entropía de la imagen original es de 7.57 bits/píxel.

Imagen barcos



Compresión DWT



Compresión DCT



Table 5: Compresión barcos

	MSE	PSNR (dB)	SSIM	CR	Entropía (bits/píxel)	Tiempo (s)
DWT	0.0021	26.84	0.9483	1.387	7.09	0.19
DCT	0.0010	29.95	0.9747	1.012	7.13	0.29

Nota: La entropía de la imagen original es de 7.12 bits/píxel.

6.1.2 Compresión SPIHT y posibles mejoras

Sobre el desempeño de la implementación realizada se puede ver con detalle en el archivo `Pruebas_SPIHT.Rmd` de la carpeta `explicaciones_y_pruebas/`, pero en resumen se observa que el algoritmo agota todas las iteraciones posibles que puede hacer, por tanto, en teoría la imagen se ha comprimido completamente y el decodificador debería obtener una imagen muy parecida a la original. Sin embargo nada más lejos de la realidad la imagen que se obtiene es de una calidad nefasta.

Tras revisar numerosas veces el algoritmo llegamos a la conclusión de que no se trata de un fallo en el código, y hay una gran cantidad de factores que pueden causar los pobres resultados obtenidos, entre los cuales destacamos:

- La aproximación de los coeficientes wavelet hecha en el paso subordinado. En el algoritmo no se codifican los valores reales de los coeficientes wavelet si no una aproximación que en algunos casos pensamos puede ser muy burda y es la causa de los malos resultados.
- La wavelet madre usada no es la adecuada, puede ser que usando alguna wavelet específica los resultados mejoren. En nuestro caso tras hacer pruebas con las wavelets de `haar`, `d8` y `d4` no se han obtenido resultados de mejor calidad.
- El rango de coeficientes wavelet de la imagen escogida es desafortunadamente bajo. Es posible que los coeficientes wavelet para la imagen estén repartidos en un rango de valores muy pequeños y eso cause una mala aproximación. Una posible solución sería multiplicar por una constante, lo cual produciría como efecto secundario un aumento en el tiempo de ejecución, sin embargo se han hecho pruebas y los resultados a penas mejoran.

Es posible que con más tiempo y usando herramientas más avanzadas se pudiera hacer una mejor implementación del algoritmo, consiguiendo mayor precisión y rapidez, sin embargo no disponemos de ese tiempo.




Table 6: Compresión barcos SPIHT

	MSE	PSNR (dB)	SSIM	CR	Entropía (bits/píxel)	Tiempo (s)
SPIHT	0.2405	6.19	0.7578	48.28	4.97	179.31

Nota: La entropía de la imagen original es de 7.12 bits/píxel.

6.2 Compresión de vídeo


Para realizar la compresión del vídeo se ha decidido separar el audio y las imágenes por separado.

6.2.1 Compresión de imágenes del vídeo

La compresión de los frames del vídeo se ha realizado mediante el método DCT, reutilizando exactamente el mismo procedimiento desarrollado para la compresión de imágenes individuales. A partir del vídeo original se extraen 223 imágenes a 30 fotogramas por segundo y se aplica el algoritmo de compresión de forma iterativa a cada una de ellas.


6.2.2 Compresión del audio del vídeo

Para buscar el mejor parámetro umbral se va a buscar aquel valor que tiene una alta reducción del archivo y un bajo valor de la redundancia, debido a que cuanto más se acerque a la redundancia de la señal sin comprimir menos información pierde. En la siguiente figura se representa el porcentaje de archivo comprimido frente a la redundancia de la señal wavelet. Para el cálculo de la entropía se va a utilizar un número de bins fijo a 100 por conveniencia.




Se observa que el valor óptimo, que logra un equilibrio entre una baja redundancia y la preservación de la información de la señal, corresponde a un umbral de $\lambda = 0.1$. Por tanto, este será el valor utilizado para la compresión definitiva del audio.

El mapa de calor de los coeficientes de detalle permite visualizar la distribución de la energía de la señal a través de las seis escalas wavelet. Las áreas en rojo representan coeficientes con valores cercanos a cero, mientras que las zonas amarillas y blancas indican la presencia de componentes de alta energía. Tras aplicar el umbral se observa una escasez estructural, especialmente en los niveles más finos d_1 y d_2 . En la siguiente figura se ha representado únicamente el canal izquierdo por simplicidad, pero sería análogo con el canal derecho.




Se ha aplicado una función de expansión para compensar el submuestreo intrínseco de la DWT, donde los niveles más profundos como d_6 contienen menos coeficientes que los niveles finos. Permite alinear todas las escalas con la longitud original de la señal, facilitando una comparación visual directa de la energía en cada instante de tiempo.



En la representación de la energía capturada frente al número de coeficientes se observa que una fracción reducida de los coeficientes wavelet es capaz de concentrar la mayor parte de la energía de la señal. De los casi $3 \cdot 10^5$ coeficientes, aproximadamente $2.5 \cdot 10^4$ coeficientes son suficientes para capturar alrededor del 90% de la energía total del audio.

Para ver el efecto de la señal comprimida se va a comprar la amplitud de la señal original (rojo) y la señal comprimida (negro). A pesar de haber eliminado solo un 10% de la energía hay un efecto importante en la señal como se puede ver en la figura.



Para el valor de $\lambda = 0.1$ el error cuadrático medio normalizado tras comprimir en el canal izquierdo es 0.24 y para el canal derecho 0.23. Esto indica una pérdida apreciable pero concentrada en coeficientes de baja energía, manteniendo una estructura perceptualmente reconocible de la señal.

Por lo que respecta a la tasa de compresión, obtenemos un CR de 1.13, es decir, efectivamente hemos ganado espacio en memoria tras la compresión del vídeo.

7 Conclusiones

Analizando en primer lugar las métricas de error obtenidas para las compresiones utilizando la DWT y la DCT, y de acuerdo con la descripción de las mismas hecha en el apartado de Metodología, observamos que todas ellas son relativamente satisfactorias para las cinco imágenes. Es decir, obtenemos valores del MSE cercanos a 0 y valores del PSNR altos (alrededor de 25-30 dB), índices de similitud estructural muy próximos

a 1 y entropías prácticamente idénticas a las de la imagen original (poca pérdida de información). Además, los tiempos de compilación de los algoritmos, medidos en segundos, son relativamente bajos.

La aparición de tasas de compresión (CR) menores que 1 y su relación con el codificador a la hora de guardar la imagen ya se ha comentado brevemente en el apartad de Resultados.

Si comparamos los dos métodos entre sí, podemos concluir que la DCT obtiene mejores resultados en cuanto a la fidelidad matemática y visual de las imágenes comprimidas con la original, con valores del MSE más bajos y valores del PSNR, SSIM y entropía superiores en todas las imágenes probadas. Ahora bien, el tiempo de ejecución de esta compresión es mayor y, salvo en imágenes pequeñas como en la generada con inteligencia artificial y la de los barcos, el tamaño del archivo final es más grande que el original. Es por ello que, si nuestro interés fuera únicamente el ahorro computacional, tanto en tiempo como en espacio en memoria, y no nos importase tanto la preservación de la “calidad visual” de las imágenes, sería más recomendable usar la compresión con DWT.

Por lo que respecta a la codificación SPIHT, las métricas de error obtenidas respaldan los comentarios hechos en la sección de Compresión SPIHT y posibles mejoras. Resumidamente, obtenemos un MSE bastante superior al de las compresiones con los algoritmos DWT y DCT de la misma imagen y magnitudes del PSNR, el SSIM y la entropía considerablemente más bajas. Además, el tiempo de compilación se dispara con respecto a las otras compresiones, haciendo la implementación del algoritmo poco óptima. La tasa de compresión lograda es la única métrica favorable, siendo esta extremadamente superior a la de los otros algoritmos (cerca de 50 cuando las otras no llegan ni a 2).

Por último, en cuanto al vídeo, la compresión del audio en el domino wavelet permite concentrar la mayor parte de la energía del audio en un número reducido de coeficientes de detalle, haciendo posible eliminar la mayoría de ellos mediante un umbralado energético sin pérdida significativa de información y logrando así una compresión eficiente. Un umbral de $\lambda = 0.1$ es el punto óptimo para reducir el peso del archivo sin perder la esencia de la señal sonora.

El resultado del vídeo comprimido se puede observar en el siguiente enlace https://github.com/JuanAlcarazAED/Trabajo_AS/blob/main/data_comp/video_comp.mp4

8 Link del repositorio

https://github.com/JuanAlcarazAED/Trabajo_AS.git

Referencias

- [1] R. C. Gonzalez and R. E. Woods, *Digital image processing*, 4th ed. Pearson, 2018.
- [2] G. J. Sullivan and T. Wiegand, “Video compression—from concepts to the h.264/AVC standard,” *Proceedings of the IEEE*, vol. 93, no. 1, pp. 18–31, 2005.
- [3] Á. L. Perales Gómez, “DCT para la compresión de imágenes con perdida de calidad,” Universidad de Murcia, Facultad de Informática, Documento Técnico, s.f.
- [4] P. C. Y. K. R. Rao, *The transform and data compression handbook*. CRC Press.
- [5] S. Mallat, *A wavelet tour of signal processing: The sparse way*, 3rd ed. Academic Press, 2009.
- [6] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image quality assessment: From error visibility to structural similarity,” *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004.